



Tech Challenge - Fase 2

Victor Schiavone Campos - RM 370608

Juliana Bahia - RM: 370343

Guilherme Ledier - RM: 374017

Gisele Domingues - RM: 370873

Alexandre Amaro - RM: 373449

1. Compreensão do Problema

A avaliação da qualidade de um vinho é um processo que normalmente envolve análises físico-químicas e avaliações sensoriais realizadas por especialistas. Nesse contexto, surge a seguinte questão: **é possível prever a qualidade de um vinho utilizando apenas suas características físico-químicas?**

Para responder a essa pergunta, foi utilizada a base WineQT, composta por informações relacionadas à composição química dos vinhos, como acidez, teor alcoólico, densidade, sulfatos e outras variáveis relevantes. O objetivo deste projeto é desenvolver e comparar dois modelos de Machine Learning capazes de classificar os vinhos em duas categorias:

- Baixa/Média Qualidade
- Alta Qualidade

Para isso, a variável original de qualidade foi transformada em uma variável binária, considerando:

Variável Alvo (Target)

- $\text{quality} \geq 7 \rightarrow \text{Alta Qualidade (1)}$
- $\text{quality} < 7 \rightarrow \text{Baixa/Média Qualidade (0)}$

Essa abordagem permite tratar o problema como uma tarefa de classificação binária, tornando possível comparar diferentes

algoritmos de Machine Learning e avaliar sua capacidade de prever a qualidade dos vinhos.

2. Análise Exploratória dos Dados (EDA)

A Análise Exploratória dos Dados (Exploratory Data Analysis – EDA) foi realizada com o objetivo de compreender a estrutura da base WineQT e identificar padrões relevantes para o desenvolvimento dos modelos de Machine Learning. Nesta etapa, foram avaliadas a distribuição das variáveis, o balanceamento das classes definidas para o problema, a presença de possíveis valores atípicos e as relações existentes entre os atributos físico-químicos dos vinhos. A compreensão desses aspectos é fundamental para garantir que as etapas de pré-processamento e modelagem sejam conduzidas de forma adequada, contribuindo para a construção de modelos mais consistentes e confiáveis.

2.1 Distribuição das Classes

Analisando a figura 1:




Figura 1: Distribuição das classes da variável alvo (high_quality)

A primeira análise realizada teve como foco a distribuição da variável alvo criada para o projeto.

Após a transformação da variável original de qualidade em uma classificação binária, os vinhos passaram a ser divididos em duas categorias:

- Classe 0: vinhos de baixa/média qualidade;
- Classe 1: vinhos de alta qualidade.

A distribuição observada evidencia um desbalanceamento entre as classes, com predominância de registros pertencentes à classe de baixa/média qualidade.

Esse comportamento é relevante para o desenvolvimento dos modelos de Machine Learning, uma vez que bases desbalanceadas podem influenciar o desempenho dos algoritmos e dificultar a identificação da classe minoritária.

Dessa forma, a avaliação dos modelos não foi baseada exclusivamente na acurácia, sendo também consideradas métricas como Precision, Recall, F1-Score e AUC, capazes de fornecer uma análise mais completa do desempenho dos algoritmos. A identificação desse comportamento foi fundamental para orientar as etapas seguintes de modelagem e avaliação dos algoritmos, garantindo uma análise mais adequada do desempenho dos modelos desenvolvidos.

2.2 Correlação entre as variáveis




Figura 2: Heatmap de correlação entre as variáveis físico-químicas dos vinhos.

Com o objetivo de compreender melhor os fatores associados à qualidade dos vinhos, foi realizada uma análise de correlação entre todas as variáveis físico-químicas presentes na base WineQT.

O heatmap foi uma ferramenta fundamental nesta etapa, pois permitiu visualizar rapidamente quais atributos apresentavam maior associação com a variável de qualidade, além de evidenciar possíveis relações entre as próprias variáveis explicativas.

Essa análise foi especialmente importante para o projeto por três motivos principais:

1. Identificar quais características físico-químicas poderiam contribuir de forma mais significativa para a classificação dos vinhos;
2. Compreender o comportamento geral dos dados antes da construção dos modelos;
3. Obter evidências iniciais sobre quais variáveis poderiam exercer maior influência na previsão da qualidade.

A partir dessa análise, foi possível observar que algumas características apresentavam associações mais relevantes com a variável de qualidade, indicando potencial preditivo para os modelos de Machine Learning desenvolvidos posteriormente.

Além disso, o heatmap permitiu validar que os dados continham relações consistentes e interpretáveis, reforçando a viabilidade da construção de modelos capazes de prever a qualidade dos vinhos com base em suas propriedades físico-químicas.

2.3 Distribuição do teor alcoólico




Figura 3: Distribuição dos valores de teor alcoólico presentes na base WineQT.

Com o objetivo de aprofundar a análise exploratória, foi investigada a distribuição da variável teor alcoólico (alcohol), uma das características físico-químicas que apresentou indícios de associação com a qualidade dos vinhos durante as análises anteriores.

Observa-se que a maior concentração de vinhos da base encontra-se em faixas intermediárias de teor alcoólico, principalmente entre aproximadamente 9,5% e 11,5%. À medida que os valores aumentam, a quantidade de observações torna-se progressivamente menor, formando uma distribuição assimétrica à direita.

A análise dessa variável foi considerada relevante para o projeto por dois motivos principais. Primeiramente, o teor alcoólico apresentou relação com a qualidade dos vinhos durante a análise de correlação. Além disso, compreender a distribuição dessa característica permite identificar padrões predominantes na base de dados e entender melhor o perfil dos vinhos analisados.

Sob a perspectiva de Machine Learning, essa etapa também auxilia na compreensão do comportamento dos dados antes da construção dos modelos, permitindo verificar a presença de concentrações, dispersões e possíveis características que possam influenciar o processo de classificação da qualidade dos vinhos.

2.4 Comparação do Teor Alcoólico entre as Classes




Figura 4: Comparação do teor alcoólico entre vinhos de baixa/média qualidade e alta qualidade.

Após a análise da distribuição geral do teor alcoólico, foi realizada uma comparação dessa variável entre os grupos definidos para o problema de classificação.

O boxplot foi utilizado por permitir a visualização da dispersão dos dados, dos valores centrais e da presença de possíveis valores extremos em cada uma das classes analisadas.

Observa-se uma diferença significativa entre os grupos. Os vinhos classificados como alta qualidade apresentam, em média, níveis mais elevados de teor alcoólico quando comparados aos vinhos classificados como baixa/média qualidade.

Além da diferença nas medianas, nota-se que a distribuição dos valores da classe de alta qualidade encontra-se deslocada para faixas superiores de teor alcoólico, reforçando os indícios observados anteriormente na análise de correlação.

Esse resultado sugere que o teor alcoólico possui relação relevante com a qualidade dos vinhos e pode contribuir para a capacidade dos modelos de Machine Learning em distinguir vinhos de diferentes níveis de qualidade. A análise também permitiu identificar a presença de valores extremos em ambas as classes, demonstrando a variabilidade natural existente na composição dos vinhos presentes na base de dados.

2.5 Principais Conclusões da EDA

A análise exploratória permitiu compreender melhor o comportamento das variáveis presentes na base WineQT e identificar padrões relevantes para o desenvolvimento dos modelos de Machine Learning.

Inicialmente, foi observado um desbalanceamento entre as classes definidas para o problema, com predominância de vinhos classificados como baixa/média qualidade. Esse aspecto foi considerado durante a etapa de avaliação dos modelos, motivando a utilização de métricas complementares à acurácia.

A análise de correlação evidenciou que algumas características físico-químicas apresentavam associação com a qualidade dos vinhos, destacando-se variáveis com potencial para contribuir com a capacidade preditiva dos algoritmos.

Além disso, a investigação detalhada do teor alcoólico demonstrou diferenças relevantes entre os grupos analisados, indicando que essa característica pode exercer influência significativa na distinção entre vinhos de diferentes níveis de qualidade.

De forma geral, os resultados obtidos durante a análise exploratória forneceram evidências de que os atributos físico-químicos presentes na base possuem potencial para explicar parte da variabilidade observada na qualidade dos vinhos, justificando o desenvolvimento dos modelos de classificação apresentados nas etapas seguintes do projeto.

3.Pré-processamento dos Dados

Após a análise exploratória, foi realizada a etapa de pré-processamento dos dados, com o objetivo de preparar a base para o desenvolvimento dos modelos de Machine Learning.

Essa fase foi fundamental para garantir que os algoritmos recebam dados organizados e adequados para o processo de aprendizagem, reduzindo possíveis interferências decorrentes de inconsistências, diferenças de escala ou atributos sem relevância para o problema estudado. As principais atividades realizadas envolveram a verificação da qualidade dos dados, a criação da variável alvo utilizada na classificação, a separação dos conjuntos de treino e teste e a padronização das variáveis numéricas.

3.1 Tratamento dos Dados

Inicialmente, foi realizada uma verificação da existência de valores ausentes na base de dados. A análise indicou que o conjunto de dados não possuía registros faltantes, permitindo que as etapas

seguintes fossem conduzidas sem necessidade de técnicas adicionais de imputação ou remoção de observações.

Essa verificação foi importante para garantir a integridade da base utilizada no treinamento e avaliação dos modelos.

Verificação	Resultado
Total de Registros	1.143
Total de Variáveis	13
Valores Nulos	0

Tabela 1: Resumo da qualidade inicial dos dados.

3.2 Engenharia de Atributos

Como o objetivo do projeto consiste em classificar vinhos entre alta qualidade e baixa/média qualidade, foi necessária a transformação da variável original de qualidade em uma variável binária.

Foi criada a variável denominada **high_quality**, considerando:

- $\text{quality} \geq 7 \rightarrow$ Alta Qualidade (1)
- $\text{quality} < 7 \rightarrow$ Baixa/Média Qualidade (0)

Além disso, a coluna **Id** foi removida do conjunto de dados por representar apenas um identificador dos registros, sem relação direta com as características físico-químicas dos vinhos ou com sua qualidade.

Essa etapa permitiu adequar a base ao problema de classificação binária proposto pelo desafio.

3.3 Separação dos Dados

Após a definição das variáveis explicativas e da variável alvo, os dados foram divididos em conjuntos de treinamento e teste.

Essa estratégia permite que os modelos sejam treinados utilizando apenas uma parte da base de dados e posteriormente avaliados em registros que não participaram do processo de aprendizagem.

Dessa forma, é possível obter uma estimativa mais confiável da capacidade de generalização dos algoritmos, reduzindo o risco de avaliações excessivamente otimistas.

Para este projeto, foi utilizada uma divisão de 80% dos dados para treinamento e 20% para teste.

Conjunto	Quantidade
Treino	914
Teste	229
Total	1.143

Tabela 2: Distribuição dos registros entre treino e teste.

3.4 Padronização das Variáveis

As variáveis físico-químicas presentes na base apresentam escalas diferentes. Enquanto algumas possuem valores relativamente baixos, outras apresentam amplitudes significativamente maiores.

Para evitar que variáveis com valores mais elevados exercessem influência desproporcional sobre determinados algoritmos, foi aplicada a técnica de padronização utilizando o método StandardScaler.

Esse procedimento transforma os dados para uma escala comum, preservando as relações existentes entre as observações e contribuindo para um processo de treinamento mais equilibrado.

A padronização foi aplicada utilizando exclusivamente os dados de treinamento, sendo posteriormente replicada sobre o conjunto de teste, evitando vazamento de informação entre as etapas do processo.

3.5 Conclusões do Pré-processamento

A etapa de pré-processamento permitiu preparar a base de dados para a construção dos modelos de Machine Learning.

Foram realizadas verificações de consistência, criação da variável alvo, remoção de atributos sem relevância para o problema, divisão dos dados em conjuntos de treino e teste e padronização das variáveis numéricas. Essas transformações garantiram que os algoritmos fossem treinados em uma base adequada ao problema proposto, reduzindo possíveis interferências e contribuindo para a obtenção de resultados mais confiáveis durante a etapa de modelagem.

4. Desenvolvimento dos Modelos

Após a preparação dos dados, foi iniciada a etapa de desenvolvimento dos modelos de Machine Learning.

O objetivo desta fase consistiu em treinar algoritmos capazes de classificar os vinhos entre as categorias de alta qualidade e baixa/média qualidade com base nas características físico-químicas presentes na base WineQT.

Para atender aos requisitos do desafio, foram selecionados dois modelos de classificação com abordagens distintas, permitindo comparar diferentes estratégias de aprendizagem e avaliar qual delas apresentaria melhor desempenho para o problema proposto.

4.1 Escolha dos Algoritmos

Foram selecionados dois algoritmos de classificação estudados durante as aulas e amplamente utilizados em problemas de Machine Learning:

- Regressão Logística
- Random Forest

A escolha desses modelos foi realizada com o objetivo de comparar abordagens distintas de classificação.

4.2 Regressão Logística

A Regressão Logística foi utilizada como modelo de referência (baseline) para o problema de classificação.

Esse algoritmo é amplamente empregado em tarefas de classificação binária e apresenta a vantagem de possuir estrutura relativamente simples e resultados de fácil interpretação. Sua utilização neste challenge permitiu estabelecer um ponto inicial de comparação para avaliar o desempenho de modelos mais sofisticados.

4.3 Random Forest

O Random Forest foi escolhido por representar uma abordagem baseada em árvores de decisão, capaz de capturar relações não lineares entre as variáveis. O algoritmo funciona por meio da combinação de múltiplas árvores de decisão, reduzindo a influência de decisões individuais e aumentando a robustez das previsões realizadas.

Além do potencial para alcançar elevado desempenho em tarefas de classificação, o modelo também permite avaliar a importância

das variáveis utilizadas no processo de decisão, contribuindo para a interpretação dos resultados obtidos.

4.4 Treinamento dos Modelos

Após a definição dos algoritmos, os modelos foram treinados utilizando o conjunto de treinamento previamente preparado durante a etapa de pré-processamento. Cada algoritmo recebeu os mesmos dados de entrada, permitindo que a comparação de desempenho fosse realizada de forma justa e consistente.

Os modelos treinados foram posteriormente avaliados utilizando o conjunto de teste, composto por registros que não participaram do processo de aprendizagem, possibilitando uma análise mais confiável da capacidade de classificação dos algoritmos.

Modelo	Tipo
Regressão Logística	Classificação Linear
Random Forest	Ensemble baseado em Árvores

Tabela 3: Modelos de classificação utilizados no projeto.

5. Avaliação dos Modelos

Após o treinamento dos modelos, foi realizada a etapa de avaliação de desempenho com o objetivo de verificar a capacidade de cada algoritmo em classificar corretamente os vinhos entre as categorias de alta qualidade e baixa/média qualidade.

Considerando o desbalanceamento identificado durante a análise exploratória, a avaliação não foi baseada exclusivamente na acurácia. Dessa forma, foram utilizadas métricas complementares

capazes de fornecer uma visão mais abrangente do desempenho dos modelos.

A partir dessa análise, tornou-se possível comparar os algoritmos desenvolvidos e identificar qual deles apresentou os melhores resultados para o problema proposto.

5.1 Métricas Utilizadas

Para avaliar o desempenho dos modelos desenvolvidos, foram utilizadas diferentes métricas de classificação. A utilização de múltiplas métricas foi considerada importante devido ao desbalanceamento identificado entre as classes durante a etapa de análise exploratória dos dados.

A primeira métrica analisada foi a **Accuracy** (Acurácia), responsável por medir a proporção total de classificações corretas realizadas pelo modelo. Embora seja uma métrica amplamente utilizada, sua interpretação isolada pode ser limitada em cenários com desbalanceamento entre classes.

Também foi utilizada a **Precision** (Precisão), que indica a proporção de previsões positivas realizadas corretamente pelo algoritmo. Essa métrica permite avaliar a confiabilidade das classificações identificadas como vinhos de alta qualidade.

O **Recall** (Sensibilidade) foi empregado para medir a capacidade dos modelos em identificar corretamente os vinhos pertencentes à classe de alta qualidade. Quanto maior o Recall, menor a quantidade de casos positivos não identificados pelo algoritmo.

Além disso, foi analisado o **F1-Score**, métrica que combina Precision e Recall em uma única medida. O F1-Score é especialmente relevante em problemas com desbalanceamento de classes, pois permite avaliar o equilíbrio entre a identificação correta dos casos positivos e a redução de classificações incorretas.

Por fim, foi utilizada a métrica **ROC AUC** (Área Sob a Curva ROC), que avalia a capacidade do modelo em distinguir corretamente as diferentes classes ao longo de diversos limiares de classificação. Valores mais próximos de 1 indicam maior capacidade de separação entre os grupos analisados.

A combinação dessas métricas permitiu realizar uma avaliação mais abrangente dos modelos desenvolvidos, reduzindo a dependência de uma única medida de desempenho.

5.2 Resultados Obtidos

Após o treinamento dos modelos, foram calculadas as métricas de desempenho definidas na etapa anterior.

Os resultados obtidos permitem avaliar a capacidade de cada algoritmo em classificar corretamente os vinhos entre as categorias de alta qualidade e baixa/média qualidade, fornecendo uma visão quantitativa do desempenho alcançado por cada abordagem de Machine Learning.

Modelo	Accuracy	Precision	Recall	F1-Score	AUC
Regressão Logística	90,83%	65,22%	53,57%	58,82%	90,10%
Random Forest	91,70%	69,57%	57,14%	62,75%	95,91%

Tabela 4: Comparação das métricas de desempenho dos modelos avaliados.

A análise dos resultados demonstra que ambos os modelos apresentaram desempenho satisfatório na tarefa de classificação proposta.

A Regressão Logística atingiu uma acurácia superior a 90%, demonstrando boa capacidade de identificar padrões presentes nos dados. Além disso, apresentou resultados consistentes nas métricas de Precision, Recall e F1-Score.

Entretanto, o modelo Random Forest apresentou desempenho superior em todas as métricas avaliadas. A acurácia alcançou 91,70%, enquanto a área sob a curva ROC (AUC) atingiu 95,91%, indicando excelente capacidade de separação entre os vinhos classificados como alta qualidade e baixa/média qualidade.

Também foram observados ganhos em Precision, Recall e F1-Score, demonstrando que o Random Forest apresentou melhor equilíbrio entre a identificação correta dos vinhos de alta qualidade e a redução de classificações incorretas.

Os resultados sugerem que a abordagem baseada em múltiplas árvores de decisão foi capaz de capturar relações mais complexas entre as características físico-químicas dos vinhos, proporcionando desempenho superior ao modelo linear utilizado como referência.

5.3 Comparação dos Modelos

A comparação dos resultados permitiu avaliar o comportamento dos dois algoritmos diante do mesmo problema de classificação. Embora ambos os modelos tenham apresentado desempenho satisfatório, foram observadas diferenças relevantes em sua capacidade de identificar corretamente os vinhos classificados como alta qualidade.

Além da análise das métricas apresentadas anteriormente, a comparação das curvas ROC fornece uma visão complementar sobre a capacidade de separação entre as classes.




Figura 5: Comparação das curvas ROC dos modelos avaliados.

A análise da curva ROC reforça os resultados observados nas métricas de desempenho.

O modelo Random Forest apresentou uma área sob a curva (AUC) de 95,91%, superior aos 90,10% obtidos pela Regressão Logística. Esse resultado indica maior capacidade de distinguir corretamente os vinhos pertencentes às diferentes categorias de qualidade. Embora a diferença de acurácia entre os modelos tenha sido relativamente pequena, observa-se que o Random Forest apresentou ganhos consistentes em Precision, Recall e F1-Score, demonstrando desempenho superior de forma equilibrada.

Esse comportamento sugere que o modelo baseado em árvores de decisão foi capaz de explorar melhor as relações existentes entre as características físico-químicas presentes na base de dados,

capturando padrões que não foram totalmente identificados pela abordagem linear da Regressão Logística.

5.4 Considerações sobre o Desempenho

Os resultados obtidos demonstram que ambos os modelos foram capazes de identificar padrões relevantes presentes nas características físico-químicas dos vinhos, alcançando desempenho satisfatório na tarefa de classificação proposta.

A Regressão Logística apresentou resultados consistentes e serviu como um importante modelo de referência para o projeto, demonstrando que as variáveis analisadas possuem capacidade preditiva significativa.

Entretanto, o **Random Forest** apresentou desempenho superior em todas as métricas avaliadas, incluindo Accuracy, Precision, Recall, F1-Score e ROC AUC. Além disso, a análise da curva ROC evidenciou maior capacidade de separação entre as classes, reforçando a superioridade do modelo.

Dessa forma, considerando o conjunto de métricas analisadas, o Random Forest foi definido como o modelo mais adequado para a classificação da qualidade dos vinhos dentro do contexto deste projeto.

6. Interpretação dos Resultados

Após a avaliação dos modelos, foi realizada a interpretação dos resultados obtidos com o objetivo de compreender quais características físico-químicas apresentaram maior influência na classificação da qualidade dos vinhos. Essa etapa é importante porque permite transformar os resultados estatísticos dos modelos em informações úteis para a compreensão do problema estudado,

aproximando a análise do contexto real de produção e avaliação da qualidade dos vinhos.

6.1 Variáveis com Maior Influência na Qualidade dos Vinhos




Figura 6: Importância das variáveis calculadas pelo modelo Random Forest.

O modelo Random Forest permite estimar a importância relativa de cada variável utilizada durante o processo de classificação.

Os resultados indicam que o teor alcoólico (alcohol) foi a característica mais relevante para a identificação da qualidade dos vinhos, apresentando importância superior às demais variáveis analisadas. Além do teor alcoólico, destacaram-se as variáveis sulphates, volatile acidity, density e citric acid, demonstrando contribuição significativa para o processo de classificação.

Esses resultados reforçam os padrões observados durante a análise exploratória dos dados. Em especial, o teor alcoólico já havia apresentado indícios de associação com a qualidade dos vinhos nas análises de correlação, distribuição e comparação entre classes.

Dessa forma, observa-se uma consistência entre as evidências encontradas na etapa exploratória e os resultados obtidos pelo modelo de Machine Learning selecionado.

6.2 Implicações para a Produção dos Vinhos

Os resultados obtidos sugerem que determinadas características físico-químicas possuem relação relevante com a percepção de qualidade dos vinhos presentes na base analisada. Em particular, o teor alcoólico apresentou forte associação com a classificação dos vinhos de alta qualidade, indicando que essa característica pode representar um importante indicador durante processos de monitoramento e controle de produção. Além disso, variáveis relacionadas à composição química, como sulfatos, acidez volátil e ácido cítrico, também demonstraram influência significativa, evidenciando que a qualidade do vinho depende da interação entre múltiplos fatores físico-químicos.

Embora os resultados não permitam estabelecer relações causais, eles fornecem evidências úteis para apoiar análises futuras e auxiliar na compreensão dos fatores associados à qualidade dos vinhos.

6.3 Considerações Finais do Tech Challenge

O presente Tech Challenge teve como objetivo desenvolver modelos de Machine Learning capazes de classificar vinhos entre as categorias de alta qualidade e baixa/média qualidade utilizando exclusivamente características físico-químicas. A análise exploratória permitiu compreender o comportamento dos dados e identificar padrões relevantes para o problema estudado. Posteriormente, a etapa de pré-processamento preparou a base para o desenvolvimento dos modelos de classificação.

Foram avaliados os algoritmos **Regressão Logística e Random Forest**, sendo este último o modelo que apresentou melhor desempenho em todas as métricas analisadas, alcançando os melhores resultados de Accuracy, Precision, Recall, F1-Score e ROC AUC. Além do bom desempenho preditivo, a análise de importância das variáveis permitiu identificar quais características exerceram maior influência na classificação dos vinhos, destacando principalmente o teor alcoólico.

Dessa forma, conclui-se que as informações físico-químicas presentes na base WineQT possuem capacidade significativa para auxiliar na previsão da qualidade dos vinhos, demonstrando o potencial da aplicação de técnicas de Machine Learning nesse contexto.

Observação: Uma análise complementar indicou um possível indício de overfitting no modelo Random Forest, evidenciado pela diferença entre a acurácia obtida no conjunto de treinamento (100%) e no conjunto de teste (91,7%). Ainda assim, o modelo manteve elevado desempenho nos dados não vistos, indicando boa capacidade de generalização. Como o objetivo deste projeto foi comparar e interpretar modelos de classificação, não foi realizada otimização de hiperparâmetros nesta etapa.

Links do Tech Challenge – Fase 2

- Repositório do Github

<https://github.com/vicagt/wine-quality-classification.git>

- Link do Vídeo

https://youtu.be/Aeo838bYFR8?si=BTgt5tatvpy8j_fO